

Challenge Level 3 강화학습 에이전트 결과 보고서

작성일: 2026.08.10 | 팀명: 5조 | 제출 대상: Level 3 (인내도 30틱) | 모델: model/level3/ppo.zip

1. 최종 성과 및 Baseline 대비 비교 (Pass 달성)

평가 지표	Rule-based Baseline	PPO 최종 모델	개선 성과 및 판정
Score (낮을수록 우수)	1490.8 점	1080.1 점	+27.5% 개선 (Pass ≤1300 달성)
Total Steps / Serviced	710.8 틱 / 84.4 대	638.6 틱 / 91.2 대	72.2틱 단축 / +6.8대 정비
Removed (이탈 차량)	15.60 대	8.83 대	43.4% 이탈 감소 (8.8대 달성)

2. 핵심 관측 및 보상 파이프라인 설계

[관측 설계] O2 확장 관측 (30차원)

- 구성: 슬롯 점유(3d) + 정비소 가동(3d) + 진행률(3d) + 대기차량 3대 x 7개 속성(21d)
- 적합도 플래그: $a_fit = 1.0 - damage$ (A 저손상) | $b_fit = 1.0$ if year ≥ 20 else 0 (B 올드카) | $c_fit = 1.0$ if size ≤ 4 else 0 (C 소형차)
- 특징: 정비소별 혜택 힌트를 관측에 명시하여 PPO 신경망의 조건 추론 부담을 크게 제거함.

[보상 & 하이퍼파라미터 설계] R1 균형 보상 & ent_coef=0.0

- 보상 수식: reward = -0.1 (시간비용) + 1.0 (배치) - 2.0 (무효배치) + 5.0*finished - 20.0*expired + 10.0*done
- 주요 파라미터: total_timesteps=500k | lr=0.0005 | ent_coef=0.0 | n_steps=2048 | batch_size=64 | gamma=0.99

3. 하이퍼파라미터 및 관측/보상 튜닝 비교 (100k steps 탐색)

실험 구분	차원 / 설정	100k Score (이탈 수)	분석 및 성과 비교
관측 O1 (기본 관측)	21d	1400.1 점 (12.55대)	기본 속성만 제공하여 조건 인식 속도 부족
관측 O2 (적합도 포함)	30d	1326.9 점 (12.06대)	최우수: 적합도 플래그 직접 제공으로 탐색 가속
관측 O3 (압축 관측)	18d	1452.5 점 (14.83대)	주요 변수 누락으로 이탈 수 증가
lr=0.0005, ent=0.01	30d / R1	1295.3 점 (11.12대)	탐색 노이즈로 30틱 이탈 완벽 차단 실패
lr=0.0005, ent=0.0 (최종)	30d / R1	1181.1 점 (9.91대)	최우수: 탐색 노이즈 제거하여 확정적 이탈 차단

4. 핵심 결과 분석 및 결론

- O2 관측 피쳐 엔지니어링: A(damage), B(year), C(size) 조건별 정비시간 차이를 관측 플래그(a/b/c_fit)로 제공해 조건 추론 부담을 크게 줄임.
- ent_coef=0.0 결정론적 정책: 인내도가 30틱으로 매우 짧아 무작위 탐색 노이즈가 곧바로 이탈(벌점 50)로 연결됨. ent_coef=0.0으로 확정적 배치를 밀어붙여 이탈 수를 15.60대에서 8.83대로 대폭 감소시킴.
- 최종 성과: 500k 학습 모델은 Score 1080.1 (Pass 판정)을 달성하여 5조의 목표를 성공적으로 이뤄냄.